Derin Öğrenme ile Deepfake Yüz Görüntülerinin Tespiti

1. Problem

Bu çalışma, yüz ağırlıklı fotoğrafları REAL ve FAKE olarak sınıflandıran bir derin öğrenme sistemi geliştirmeyi amaçlar. Etiket sırası `0 = REAL`, `1 = FAKE` olarak sabittir. Precision, recall, F1 ve ROC-AUC için pozitif sınıf FAKE'tir. Sistem genel amaçlı AI-generated image detector değildir.

2. Datasetler

Dataset	Train	Validation	Test	Toplam
İlk fotoğraf dataseti / V1	9.023	1.933	1.934	12.890
140k Real and Fake Faces / V2–V3	100.000	20.000	20.000	140.000

İlk dataset 5.890 REAL ve 7.000 FAKE görüntü içerir. Bilinen augmentation aileleri ve birebir kopyalar aynı ayrımda tutularak seed 42 ile yaklaşık %70/%15/%15 grup ayrımı yapılmıştır. Kaynak/kişi kimlikleri eksik olduğundan tam kişi bağımsızlığı kanıtlanamamıştır.

İkinci datasetin hazır train/valid/test ayrımları değiştirilmemiştir. Her ayrım %50 REAL / %50 FAKE dengelidir: train 50.000+50.000; validation ve test 10.000+10.000. V2 final test kaydı, test içinde sıfır birebir SHA-256 kopyası ve test–train/validation arasında sıfır SHA-256 çakışması bildirir. Bu kontrol yakın kopya veya kişi düzeyinde bağımsızlık kanıtı değildir. Datasetler `data/raw/` ve `data/real_vs_fake/` yollarıyla kullanılır; yerelde ikinci klasörün mevcut adı `data/real-vs-fake/`tir.

3. EfficientNet-B0

Üç model de torchvision EfficientNet-B0 mimarisini ve iki çıkışlı son sınıflandırma katmanını kullanır. Standart CLEAN dönüşümü EXIF yön düzeltme, RGB dönüşümü, bilinear/antialias 224×224 yeniden boyutlandırma ve ImageNet normalizasyonudur. Eğitim NVIDIA GTX 1650 4 GB üzerinde batch size 8 ve mixed precision ile gerçekleştirilmiştir.

4. Transfer learning

Modeller ImageNet `IMAGENET1K_V1` pretrained ağırlıklarıyla başlatılmış; son classification katmanı REAL/FAKE için uyarlanmıştır. AdamW, başlangıç learning rate `3e-4`, seed 42 ve Windows uyumlu workers 0 kullanılmıştır. Checkpoint seçimi yalnızca CLEAN validation FAKE F1 üzerinden yapılmıştır.

5. V1

İlk fotoğraf datasetinde eğitilen baseline'ın best epoch'u 5'tir. Early stopping epoch 8'de eğitimi durdurmuştur. Ayrılmış 1.934 test görüntüsünde accuracy %95.450, F1 %95.712 ve ROC-AUC 0.99185736 elde edilmiştir. Bu sonuç ilk datasetin test ayrımıyla sınırlıdır.

6. V2

140k Real and Fake Faces ile eğitilen V2'nin best epoch'u 3'tür. Dört epoch eğitim logu vardır; bu çalıştırma early stopping olarak raporlanmaz. 20.000 CLEAN test görüntüsünde accuracy %99.410 ve F1 %99.409 elde edilmiştir.

Ölçü	V1	V2	V3
Best epoch	5	3	5
Accuracy (%)	95.450	99.410	99.635
Precision FAKE (%)	98.004	99.569	99.789
Recall FAKE (%)	93.524	99.250	99.480
F1 FAKE (%)	95.712	99.409	99.634
ROC-AUC	0.99185736	0.99825422	0.99992647

V1 farklı bir datasetin test ayrımında ölçülmüştür. Bu tablo ortak benchmark veya mimari/dataset büyüklüğünün nedensel etkisi olarak yorumlanamaz. V2 ve V3 aynı 20.000 test görüntüsünde değerlendirilmiştir.

7. Robustness problemi

V2'nin yüksek CLEAN başarısı kalite bozulmalarına dayanıklılık anlamına gelmemiştir. Blur sigma 1/2 ve 224→112→224 resize altında accuracy yaklaşık %50'ye düşmüş, FAKE örnekler büyük ölçüde REAL olarak sınıflandırılmıştır. Yüksek frekanslı görsel ipuçlarına duyarlılık olası bir açıklamadır; gözlem tek başına nedensel kanıt değildir.

8. V3 augmentation yaklaşımı

V3 Robust EfficientNet-B0, aynı mimari ve dataset üzerinde yalnızca TRAIN splitinde kalite augmentation'larıyla eğitilmiştir. Validation ve final test CLEAN kalmıştır.

Augmentation	Olasılık	Aralık
JPEG compression	%50	Quality 50–95
Gaussian blur	%15	Sigma 0.1–1.5
Gaussian noise	%15	RGB [0,1], std 0–0.02
Downscale/upscale	%30	224→rastgele 112–224→224
Horizontal flip	%50	Yatay çevirme

Maksimum 6 epoch ve early stopping patience 2 kullanılmış; altı epoch tamamlanmıştır. Best epoch 5'tir; epoch sınırında patience dolmadığından duruş early stopping değildir.

V2 → V3 robustness

Koşul	V2 accuracy (%)	V3 accuracy (%)	Artış (yüzde puan)
CLEAN	99.410	99.635	+0.225

Koşul	V2 accuracy (%)	V3 accuracy (%)	Artış (yüzde puan)
JPEG Q70	85.690	99.220	+13.530
JPEG Q50	76.340	98.525	+22.185
Blur sigma 1	50.955	98.885	+47.930
Blur sigma 2	50.005	91.030	+41.025
Noise 0.01	94.895	99.430	+4.535
Noise 0.03	75.455	97.850	+22.395
Resize 224→112→224	50.185	98.230	+48.045

En büyük accuracy artışı resize koşulunda +48.045 yüzde puandır. Blur sigma 1 ve sigma 2 altında artış sırasıyla +47.930 ve +41.025 yüzde puandır; sigma 2 hâlâ en zor koşuldur. FAKE→REAL hataları resize için 9.962→319, blur sigma 1 için 9.809→198 ve blur sigma 2 için 9.999→1.723 olarak azalmıştır.

9. Final test sonuçları

V3, 140k Real and Fake Faces test setinde %99.635 accuracy elde etmiştir. Bu ölçüm 10.000 REAL ve 10.000 FAKE olmak üzere 20.000 CLEAN test görüntüsüne aittir; tüm deepfake görüntüler için genelleme iddiası değildir.

Ölçü	V3 final
Accuracy	%99.635
Precision FAKE	%99.7893
Recall FAKE	%99.480
F1 FAKE	%99.6344
ROC-AUC	0.99992647
Doğru / toplam	19.927 / 20.000
Yanlış	73
Best epoch	5

Confusion matrix, satır gerçek / sütun tahmin ve sıra REAL, FAKE: `[[9979, 21], [52, 9948]]`. Ana model `outputs/checkpoints/best_model_v3_robust.pth` dosyasıdır. SHA-256: `c7e2c8f06a21a88bfed15f0d63d05b7a345dcae25f874cad3136313331c2ca0c`.

10. Grad-CAM

Grad-CAM, tahmin edilen sınıfın softmax öncesi logitini ve son convolution katmanını (`features.8.0`) kullanır. Harita sınıf kararına uzamsal katkıları gösterir; manipüle edilmiş piksellerin ground-truth segmentasyonu değildir. Final pakette önceki seed-42 doğru örnek sırasından ilk iki REAL ve ilk iki FAKE açıklaması yer alır; confidence'a göre sıralama yapılmamıştır. Seçilmiş doğru örnekler genel model başarısını veya nedensel karar gerekçesini kanıtlamaz. Gösterilen confidence, kalibre edilmemiş softmax skorudur.

11. Sınırlılıklar

- Başarı belirli fotoğraf datasetleri ve ölçülen kalite koşullarıyla sınırlıdır; bağımsız fotoğraf kaynaklarında aynı başarı garanti edilmez.
- V2 test/robustness gözlemleri V3 augmentation tasarımına yön vermiştir. Test eğitim veya checkpoint seçiminde kullanılmamıştır; buna rağmen V3 sonuçları geliştirme boyunca hiç görülmemiş bağımsız test olarak sunulamaz.
- Bilinen hash çakışmalarının olmaması kişi/kaynak bağımsızlığını kanıtlamaz. İkinci datasetin kaynak URL, sürüm ve lisans künyesi yerel kayıtlarda yoktur.
- Demo, eğitim dağılımına benzer yüz ağırlıklı görüntüleri sınıflandırır. Genel amaçlı AI-generated image detector değildir; görüntünün tamamı standart CLEAN pipeline'dan geçirilir.
- Loglarda train accuracy ve validation loss bulunmadığından bu eğriler üretilmemiştir; mevcut train loss ve validation metrikleri çizilmiştir.

12. Sonuç

V3, 140k Real and Fake Faces test setindeki CLEAN başarısını korurken ölçülen sıkıştırma, blur, noise ve resize koşullarında V2'ye göre daha yüksek başarı elde etmiştir. Çalışmanın ana katkısı yalnızca yüksek CLEAN accuracy değil, aynı test fotoğraflarında kalite dayanıklılığının iyileştirilmesidir. Model geliştirme tamamlanmıştır; bu paket hazırlanırken yeni eğitim, inference, model seçimi veya tuning yapılmamıştır.

Kaynak kayıtları ve sunum dosyaları

Sayısal kaynaklar `outputs/metrics/final_test_metrics*.json`, `robustness_v2.json`, `robustness_v3.json` ve üç mevcut `history.csv` dosyasıdır. Özet README ve deney günlüğü ile uyumludur. Sunum görselleri `outputs/figures/final/` altında 10 PNG ve 6 SVG olarak hazırdır; kaynak/file hash'leri `package_manifest.json` içinde bulunur. Görseller üretilmiş çıktı oldukları için Git dışında tutulur; rapor/sunum tesliminde bu klasör ayrıca paylaşılmalıdır.